

YaneCode Digital

Stage d'été 2026

Documentation du pipeline

Analyse des perceptions des développeurs face à l'IA

Stagiaire	Charifa FAX
Domaine	Data Science et analyse de sentiment
Type de document	Documentation technique - version d'avancement
Version	1.0
Date	23 juillet 2026

Ce document présente le pipeline réellement construit, les données disponibles, les décisions prises et les étapes restant à exécuter. Les éléments déjà réalisés sont séparés des travaux planifiés afin de donner une vue fidèle de l'avancement.

Table des matières

1 Synthèse exécutive	2
2 Objectif et périmètre	2
2.1 Question de recherche	2
2.2 Résultats attendus	2
3 Architecture générale	3
4 État d'avancement du pipeline	3
5 Documentation des sources de données	4
5.1 Vue d'ensemble	4
5.2 Reddit : difficulté rencontrée	4
5.3 Scripts associés	5
6 Schéma unifié des données	5
7 Audit de qualité et règles de préparation	5
7.1 Résultats de l'audit	5
7.2 Correction principale : mot-clé ai	6
7.3 Pourquoi conserver plusieurs textes	6
8 Analyses planifiées	6
8.1 Analyse exploratoire	6
8.2 Analyse de sentiment	6
8.3 Topic modeling et clustering	6
9 Dashboard, tests et démonstration	6
10 Organisation du dépôt	7
11 Limites et principes d'interprétation	7
12 Prochaines actions	7

1 Synthèse exécutive

Le projet vise à analyser les opinions et tendances émotionnelles exprimées par des développeurs au sujet des outils d'intelligence artificielle : ChatGPT, GitHub Copilot, Cursor, Claude, Gemini, DeepSeek, LLM et agents IA.

La collecte est terminée et le corpus brut contient **5 406 documents**. Les restrictions d'accès à l'API Reddit ont conduit à une stratégie multi-source : Reddit via Arctic Shift, deux jeux de données Hugging Face, GitHub Issues, Stack Overflow et Hacker News. Un audit a ensuite mis en évidence un filtrage trop large autour du mot-clé **ai**. La correction de cette règle et la déduplication textuelle ont produit un sous-ensemble de **2 666 documents prêts pour l'analyse**.

La prochaine étape technique est l'analyse exploratoire, suivie de la comparaison de deux méthodes de sentiment, du topic modeling, du clustering et du dashboard.

2 Objectif et périmètre


2.1 Question de recherche

Comment les développeurs perçoivent-ils les outils modernes d'intelligence artificielle et les assistants de programmation ?

2.2 Résultats attendus

- un dataset propre, documenté et reproductible ;
- des visualisations sur les sources, les outils IA et l'évolution temporelle ;
- une comparaison d'au moins deux méthodes d'analyse de sentiment ;
- une identification des thèmes dominants et des groupes de textes ;
- un dashboard Streamlit/Plotly ;
- une démonstration simple accompagnée de tests et de limites clairement formulées.

3 Architecture générale



4 État d'avancement du pipeline

Phase	Statut	Preuve ou livrable
Cadrage et problématique	Réalisé	Question de recherche, objectifs et périmètre définis.
Choix des sources et mots-clés	Réalisé	Sources et mots-clés documentés dans les scripts.
Collecte multi-source	Réalisé	Quatre collecteurs Python, deux datasets externes et corpus fusionné.
Audit et compréhension des données	Réalisé	Notebook d'inspection et synthèse de qualité.
Nettoyage et préparation	Réalisé	Script reproductible et dataset d'analyse de 2 666 lignes.
Analyse exploratoire	Planifié	Visualisations par source, date, outil IA et longueur des textes.
Sentiment analysis	Planifié	VADER puis modèle Transformer, validés sur un échantillon humain.
Topic modeling et clustering	Planifié	TF-IDF + NMF et TF-IDF + K-Means.
Dashboard	Planifié	Application Streamlit avec filtres et exemples représentatifs.
Tests et démonstration	Planifié	Scénario nominal, limite et anomalie.

5 Documentation des sources de données

5.1 Vue d'ensemble

Source	Plateforme	Méthode et périmètre	Lignes
Arctic Shift	Reddit	Archive publique. Collecte des publications récentes de communautés liées à l'IA, la programmation, le web et les carrières logicielles.	305
hnam25/uit-sentiment-dataset-reddit-2000-balanced	Reddit	Dataset Hugging Face de 2 000 publications Reddit liées à l'IA, avec étiquettes de sentiment fournies par la source.	2 000
divde/sentiment_posts	Multi-source	Dataset Hugging Face filtré avec les mots-clés du projet. Plusieurs lignes ne disposent pas de l'ensemble des métadonnées temporelles.	141
Hacker News	Hacker News	API Firebase publique. Les 1 000 histoires les plus récentes ont été parcourues puis filtrées.	236
GitHub Issues	GitHub	API REST publique. Issues, hors pull requests, issues de 17 dépôts logiciels populaires.	1 616
Stack Overflow	Stack Overflow	API Stack Exchange. Questions publiées depuis 2025, incluant contenu HTML et métadonnées de votes/réponses.	1 108
Total		Corpus brut fusionné	5 406

5.2 Reddit : difficulté rencontrée

Le plan initial prévoyait l'API officielle Reddit. Les requêtes JSON non authentifiées ont renvoyé une erreur HTTP 403. PullPush a ensuite été testé, mais les limites de débit n'ont pas permis d'obtenir un corpus stable. Une demande d'accès a été envoyée à Reddit, sans réponse au moment de cette version.

La continuité du projet a été assurée par Arctic Shift et par des datasets publics documentés. Cette décision doit être conservée dans le rapport comme une **limitation de collecte**, et non comme une preuve de représentativité de Reddit en temps réel.

5.3 Scripts associés

Fichier	Rôle
<code>reddit_public_collector.py</code>	Collecte Reddit via Arctic Shift, avec anciens backends conservés comme solutions de repli.
<code>github_collector.py</code>	Collecte et normalisation des GitHub Issues.
<code>hn_collector.py</code>	Collecte des histoires Hacker News via Firebase.
<code>stackoverflow_collector.py</code>	Collecte de questions Stack Overflow via l'API Stack Exchange.
<code>prepare_analysis_dataset.py</code>	Audit, normalisation, filtrage strict, déduplication et export du dataset d'analyse.

6 Schéma unifié des données

Le grain retenu est : **un document = une publication, une issue, une histoire ou une question**. Les commentaires ne font pas encore partie du corpus principal.

Champ	Définition
<code>record_id</code>	Identifiant unique construit à partir de la source et de l'identifiant natif.
<code>source, platform</code>	Origine technique et plateforme normalisée.
<code>community</code>	Subreddit, dépôt GitHub ou catégorie de provenance.
<code>title_raw,</code> <code>body_raw</code>	Texte d'origine, conservé sans modification destructive.
<code>full_text_raw</code>	Fusion du titre et du corps.
<code>text_clean_basic</code>	HTML et URL supprimés ; ponctuation et négations conservées.
<code>text_clean_lexical</code>	Version minuscule et normalisée pour TF-IDF et topic modeling.
<code>created_at_utc</code>	Date convertie en UTC lorsqu'elle est disponible.
<code>score,</code> <code>num_comments</code>	Indicateurs d'engagement propres à chaque plateforme.
<code>ai_tools</code>	Outils IA détectés dans le texte.
<code>research_themes</code>	Indicateurs transparents de thèmes : productivité, confiance, emploi, sécurité, etc.

7 Audit de qualité et règles de préparation

7.1 Résultats de l'audit

Indicateur	Valeur
Documents bruts valides	5 406
Documents strictement liés à l'IA	2 726
Doublons textuels exacts	37
Documents sans identifiant natif	141
Documents sans date exploitable	141
Documents antérieurs à 2025	378
Documents finaux prêts pour l'analyse	2 666

7.2 Correction principale : mot-clé ai

La règle initiale cherchait "ai" comme une sous-chaîne. Elle pouvait donc sélectionner des mots sans rapport avec l'intelligence artificielle, par exemple *email*, *again* ou *maintain*. La nouvelle règle utilise des limites de mots et ajoute des expressions explicites pour ChatGPT, Copilot, Cursor, Claude, Gemini, DeepSeek, LLM, Llama, Mistral et Qwen.

7.3 Pourquoi conserver plusieurs textes

- `full_text_raw` permet l'audit et la lecture humaine ;
- `text_clean_basic` est adapté à VADER et aux Transformers, car la ponctuation et la négation portent du sentiment ;
- `text_clean_lexical` est destiné à TF-IDF, NMF et K-Means.

Le texte original n'est jamais écrasé.

8 Analyses planifiées

8.1 Analyse exploratoire

L'EDA répondra aux questions suivantes : composition du corpus par plateforme, couverture temporelle, distribution de longueur, outils IA les plus mentionnés, mots fréquents, bigrammes, trigrammes et communautés représentées. Les résultats globaux seront toujours accompagnés d'une lecture par plateforme afin d'éviter qu'une source majoritaire ne domine l'interprétation.

8.2 Analyse de sentiment

Deux niveaux sont retenus :

1. **VADER**, baseline rapide et explicable ;
2. **Transformer préentraîné**, appliqué dans un premier temps à un échantillon contrôlé.

Un échantillon manuel de 100 à 120 documents permettra d'évaluer l'accord, le macro-F1 et les principales erreurs. Les labels existants des datasets externes seront conservés séparément.

8.3 Topic modeling et clustering

Le pipeline principal utilisera TF-IDF + NMF pour produire des thèmes interprétables et TF-IDF + K-Means pour comparer une approche de clustering. Chaque thème sera validé par la lecture de documents représentatifs avant d'être nommé.

9 Dashboard, tests et démonstration

Le dashboard Streamlit présentera : nombre de documents, sentiment, thèmes, outils IA, évolution temporelle et filtres par plateforme. Trois scénarios seront documentés :

- **nominal** : texte complet et clairement lié à un outil IA ;
- **limite** : texte très court ou ambigu ;
- **anomalie** : texte vide, HTML seul ou donnée mal formée.

La démonstration suivra un parcours court : lancement, filtre par plateforme, lecture des résultats, ouverture d'un exemple et rappel des limites.

10 Organisation du dépôt

```
AI-Developer-Sentiment/  
|-- data/  
|   |-- raw/  
|   |-- processed/  
|   '-- sample/  
|-- notebooks/  
|-- src/  
|   |-- collectors/  
|   |-- preprocessing/  
|   |-- models/  
|   '-- utils/  
|-- dashboard/  
|-- tests/  
|-- docs/  
|-- figures/  
|-- report/  
|-- README.md  
|-- requirements.txt  
'-- config.yaml
```

11 Limites et principes d'interprétation

- le corpus n'est pas un sondage représentatif de tous les développeurs ;
- les plateformes ont des usages différents : discussion, support technique ou suivi d'incidents ;
- les métadonnées et la période ne sont pas identiques pour toutes les sources ;
- les modèles de sentiment génériques peuvent mal comprendre le vocabulaire technique, le sarcasme et les messages d'erreur ;
- les résultats devront être rapportés par plateforme et accompagnés d'exemples ;
- les identités individuelles ne seront pas analysées ni affichées dans le dashboard final.

12 Prochaines actions

1. valider définitivement le dataset de 2 666 documents ;
2. produire le notebook EDA et les figures principales ;
3. exécuter VADER et préparer l'échantillon manuel ;
4. lancer le modèle Transformer sur l'échantillon ;
5. appliquer NMF puis K-Means ;
6. intégrer les sorties dans Streamlit ;
7. documenter les trois tests et finaliser le rapport.